

USO DE INTELIGENCIA ARTIFICIAL PARA PREDICCIÓN DE ENFERMEDADES RESPIRATORIAS

MARIO CASTRO ESTEBAN

mcastroes.inf@upsa.es



PROYECTO FINAL INTELIGENCIA ARTIFICIAL
12 de enero de 2026

Enlace al entorno de trabajo:

https://colab.research.google.com/drive/1_AbQnilvvoGV4AVaWeah_ypaZnLJv-7e?usp=sharing

ÍNDICE

1. Introducción	3
• 1.1. Objetivos	3
• 1.2. Etapas	3
2. Marco teórico	4
• 2.1. Redes neuronales convolucionales	4
• 2.2. Segmentación U-NET	5
• 2.3. Fundamentos médicos	6
3. Metodología y diseño	7
• 3.1. Descripción del Dataset	7
• 3.2. Preprocesamiento y segmentación (U-Net)	7
• 3.3. Estructuración y división de datos procesados	8
• 3.4. Diseño del Clasificador Binario	8
• 3.5. Diseño del Clasificador Multiclase	8
• 3.6. Predicción de datos	9
4. Análisis de resultados	10
• 4.1. Evaluación de la segmentación (U-Net)	10
• 4.2. Evaluación de la clasificación binaria	10
• 4.3. Evaluación de la clasificación multiclase	10
5. Conclusiones y justificaciones	11
• 5.1. Validación de la arquitectura	11
• 5.2. Limitaciones y alcance del sistema	11
• 5.3. Eficiencia computacional	12
• 5.4. Posibles mejoras y ampliaciones.....	12
6. Anexos	13
7. Bibliografía	15

1. Introducción

El objetivo principal de este trabajo es desarrollar un sistema basado en Inteligencia Artificial que sea capaz de predecir patrones de enfermedades respiratorias en radiografías de tórax de pacientes, generando predicciones probabilísticas que señalen la existencia de anomalías y posibles tipos de enfermedades presentes.

Para ello, se usa Deep Learning, específicamente Redes Neuronales Convolucionales (CNNs), para procesar directamente las imágenes de los pulmones. Se ha diseñado una arquitectura compuesta por dos fases principales:

- **Segmentación semántica:** una etapa inicial mediante arquitectura U-NET encargada de aislar la región pulmonar y eliminar el ruido irrelevante.
- **Clasificación jerárquica:** etapas posteriores para la clasificación binaria (sano/enfermo) y clasificación multiclase del tipo de enfermedad (COVID/neumonía/opacidad pulmonar)

El entrenamiento de los modelos se ha realizado usando datos de imágenes y etiquetas, en concreto se ha usado el dataset *COVID-19 Radiography Data* de Kaggle, que incluye miles de imágenes de radiografías de tórax etiquetadas en cuatro categorías diferentes (Normal, COVID-19, Neumonía Viral y Opacidad Pulmonar), junto con sus correspondientes máscaras de segmentación.

La programación de todo el proyecto se ha realizado en un único entorno de Google Colaboratory, dónde se ha desarrollado la estructura del proyecto paso a paso, usando la biblioteca Tensorflow/Keras. Para guardar y cargar los modelos entrenados, se ha usado un repositorio de GitHub en lugar de Google Drive, ya que permite trazabilidad y acceso público a los modelos.

1.1. Objetivos

En el desarrollo del trabajo se han abordado los siguientes objetivos:

- Preprocesar imágenes médicas y normalizar sus datos para su uso en modelos predictivos.
- Implementación del sistema de forma modular mediante redes convolucionales, para abordar de forma jerárquica las tareas de clasificación (segmentación, salud y tipo de enfermedad)
- Evaluar y comparar el desempeño de distintas técnicas utilizando métricas propias de las CNNs que nos permitan leer su precisión y exactitud.
- Proporcionar resultados interpretables y útiles para analizar la capacidad del sistema de detectar anomalías en los pulmones.
- Presentar los resultados de forma clara, proporcionando conclusiones que puedan ser interpretadas fácilmente.

1.2. Etapas

El trabajo se ha desarrollado a partir de unas etapas bien definidas y diferenciadas:

- **Carga de datos:** carga del dataset en el entorno de Google Colaboratory, verificación y análisis de los archivos (radiografías y máscaras)

- **Desarrollo del modelo de segmentación U-NET:** implementación de la arquitectura U-NET con base MobileNetV2, entrenamiento utilizando las máscaras binarias del dataset y posterior predicción.
- **Transformación de los datos (aplicación de máscaras):** transformación de los datos de entrada para aislar las regiones de interés (los pulmones en este caso) Esta etapa consiste en realizar la multiplicación punto a punto entre la radiografía original y la máscara predicha por la U-NET, resultando en imágenes donde sólo el tejido pulmonar es visible, eliminando el fondo.
- **Modelado de clasificación binaria:** entrenamiento de una CNN para distinguir entre pacientes sanos y enfermos, utilizando las imágenes segmentadas.
- **Modelado de clasificación multiclase:** entrenamiento de una segunda CNN especializada para categorizar la patología (COVID-19, Neumonía, Opacidad) en los casos positivos.
- **Integración y evaluación final:** demostración de la efectividad del sistema a través de la predicción de nuevos datos.

2. Marco teórico

Antes de pasar a desarrollar el proyecto, debemos tener en cuenta ciertos aspectos teóricos que serán fundamentales para el correcto desarrollo del mismo, incluyendo el concepto de redes neuronales convolucionales (CNNs), redes de segmentación U-NET y ciertos fundamentos médicos básicos para poder entender bien el problema e interpretar los resultados correctamente.

2.1. Redes neuronales convolucionales

Las redes neuronales convolucionales (CNNs) son una arquitectura de Deep Learning que normalmente se utilizan para el reconocimiento de imágenes y detección de objetos, permitiendo su clasificación automática con alta precisión.

En lugar de procesar toda la imagen de forma inmediata, la red utiliza pequeños filtros matriciales (kernels) simétricos que se mueven sobre la imagen original. Con esto, se imita la corteza visual humana, dividiendo la imagen en diferentes niveles:

- **Capas iniciales (bajo nivel):** la red aprende a detectar rasgos simples como líneas verticales, horizontales, bordes y cambios de color.
- **Capas intermedias (nivel medio):** combina los rasgos anteriores para detectar formas, texturas o partes de objetos.
- **Capas profundas (alto nivel):** combina las formas obtenidas para distinguir objetos completos.

El proceso completo sigue una secuencia clara:

- **Input:** la imagen entra como una matriz de números (píxeles)

- **Convolución:** el kernel se mueve sobre la imagen original, realizando la multiplicación entre sus pesos y píxeles. Este proceso se ejecuta a la vez con múltiples filtros, generando una serie de mapas de características. Posteriormente, estos mapas pasan por la función de activación *ReLU*, la cual se encarga de anular los valores negativos y conservar los positivos.
- **Pooling:** una vez realizada la convolución, se aplica el proceso de *Pooling* para resumir la imagen. Esto funciona moviendo otro filtro matricial (normalmente 2x2), resumiendo la información mediante la conservación del valor más importante de cada zona. Se suele usar el método *Max Pooling*, que elige el valor máximo de la ventana y descarta el resto. Realizamos este proceso para ahorrar coste computacional.
- **Flatten:** al obtener ya todos los mapas de características resultantes tras hacer convoluciones y pooling, pasamos a reorganizarlos todos en un único vector unidimensional, para pasarlo posteriormente a la red neuronal.
- **Clasificación:** una vez que la imagen ha sido traducida a un vector numérico, la información entra a una red neuronal clásica, compuesta por capas densas. La capa de salida de la misma tiene una función de activación específica, dependiendo del problema que queramos resolver.

En resumen, las redes neuronales convolucionales trabajan en su mayoría con imágenes, con el propósito de clasificarlas. Esto se logra a través de convoluciones que extraen información de las mismas, así como con pooling para resumir dicha información lo más posible. Una vez se hayan extraído todos los mapas de características, se resumen en un único vector unidimensional, que entra a una red neuronal densa, y cuya capa de salida clasifica en función de una función de activación determinada.

En nuestro caso, las usaremos como clasificadores binarios y multiclase para analizar las radiografías de tórax, y evaluar si estamos ante unos pulmones sanos o enfermos, y si están enfermos, de qué enfermedad se trata entre COVID, Neumonía u Opacidad pulmonar.

Estructura de una CNN

2.2. Segmentación U-NET

La arquitectura U-Net es una variante especializada de las CNNs, diseñada para la segmentación de imágenes. A diferencia de las redes convolucionales tradicionales que clasifican una imagen entera con una sola etiqueta, U-Net clasifica cada píxel de manera individual para delimitar una zona de interés.

Su nombre viene de su estructura simétrica en forma de “U”: en primer lugar reduce la imagen para entender qué hay en la misma, y luego la vuelve a ampliar para saber dónde está cada elemento. El proceso completo por tanto, sigue dos caminos:

- **Camino de contracción (encoder):** es la parte izquierda de la arquitectura. Funciona exactamente igual que una red convolucional tradicional; aplica bloques de convolución + ReLu seguidos de Max Pooling. Su objetivo es reducir las dimensiones de la imagen para capturar el contexto de la misma.
- **Cuello de botella (bottleneck):** parte inferior de la arquitectura. Es el punto donde la imagen está más comprimida. Aquí la red entiende qué objetos hay, pero ha perdido la noción del espacio.

- **Camino de expansión (decoder):** parte derecha de la arquitectura. En lugar de comprimir la imagen, hace un proceso de convolución inversa. Su función es aumentar progresivamente las dimensiones de la imagen hasta recuperar el tamaño original de la entrada. El objetivo de esta etapa es extraer la ubicación del contexto, es decir, saber dónde están las características de la imagen.
- **Skip connections (conexiones de salto):** unión entre los mapas de características de alta resolución desde el camino de contracción (izquierda), y los une al camino de expansión (derecha), permitiendo recuperar la información espacial perdida y obteniendo detalles.
- **Salida (mapa de segmentación):** la capa final es una convolución 1x1. Se proyectan los mapas de características en un mapa binario (blanco y negro) donde se activa una función de activación (normalmente Sigmoide) píxel a píxel para decidir si cada punto pertenece a la máscara (1) o al fondo que queremos descartar (0)

Resumiendo, U-Net no busca clasificar una imagen, sino dibujarla. Esto lo logra a través de una estructura de “codificador-decodificador”: una primera mitad que comprime la imagen mediante convoluciones y pooling para extraer el contexto, y una segunda mitad que la expande para encontrar la localización del contexto, apoyándose en conexiones directas entre ambos lados para no perder detalles.

Estructura de un segmentador U-Net

2.3. Fundamentos médicos

Algo que debemos tener en cuenta y que es importante para poder entender las radiografías con las que estamos trabajando, es saber interpretarlas también por nosotros mismos para comprender los resultados que obtengamos. Por ello, debemos tener en cuenta estos factores para saber leer las imágenes:

- **Pulmones sanos:** en un paciente sano, los pulmones están llenos de aire, lo que permite que los rayos X pasen con facilidad. Se observan dos grandes campos oscuros negros bien definidos: son los pulmones. Los bordes del diafragma y de la silueta cardíaca son nítidos y claros, hay ausencia de manchas blancas difusas (exceptuando vasos sanguíneos) y las esquinas inferiores terminan en puntas agudas y limpias.
- **Pulmones enfermos (COVID):** se caracteriza por manchas blanquecinas tenues en los pulmones, siendo como una especie de “neblina” que dificulta ver los vasos sanguíneos detrás. Suelen aparecer en los bordes externos de los pulmones, pegadas a las costillas, y frecuentemente la enfermedad ataca a ambos pulmones.
- **Pulmones enfermos (Neumonía):** se aprecian patrones basados en una red de líneas blancas desordenadas o una borrosidad generalizada, como si el pulmón estuviera “sucio”. Se pueden ver líneas blancas más marcadas alrededor de los bronquios, y la infección tiende a estar más esparcida y no tan focalizada en parches difusos.
- **Pulmones enfermos (Opacidad pulmonar):** esta categoría suele agrupar casos de naturaleza no viral, como por ejemplo infecciones bacterianas. En estos casos, los sacos de aire se llenan completamente de pus o líquido, bloqueando totalmente los rayos X. Es por ello que se distinguen por tener manchas blancas sólidas.

Es importante mencionar que las radiografías de pulmones con COVID y pulmones con opacidad pulmonar pueden verse similares, ya que ambas patologías provocan características visuales parecidas, y es por ello que nuestro modelo de IA puede llegar a confundirse entre las dos en ocasiones.

[Análisis visual](#)

3. Metodología y diseño

En esta sección se detalla de forma textual el procedimiento llevado a cabo para el desarrollo del sistema. El trabajo se ha llevado a cabo en un entorno de Google Colaboratory, utilizando la biblioteca Tensorflow/Keras, y se divide en cuatro etapas principales: preparación de los datos, segmentación pulmonar, diseño de la arquitectura y configuración del entrenamiento.

3.1. Descripción del Dataset

Para el entrenamiento y validación de los modelos se ha utilizado el conjunto de datos público *COVID-19 Radiography Database*, desarrollado por investigadores de la Universidad de Qatar y la Universidad de Dhaka, entre otros.

El dataset consiste de imágenes de radiografías de tórax organizadas en cuatro categorías:

- **Normal:** pacientes sanos sin enfermedades visibles.
- **COVID-19:** pacientes positivos de COVID-19.
- **Viral Pneumonia:** pacientes con neumonía de origen viral.
- **Opacidad pulmonar:** pacientes con opacidades pulmonares de origen no viral (generalmente bacteriano)

3.2. Preprocesamiento y segmentación (U-Net)

Uno de los principales problemas que nos encontramos en el análisis de las radiografías es el “ruido” visual causado por estructuras y tejidos que no sean los pulmones, lo cual puede confundir al clasificador.

Para solucionar esto, se ha implementado una etapa de preprocesamiento basada en una red de segmentación U-Net, a través de estos pasos:

- **Redimensionado y normalización:** todas las imágenes han sido reescaladas a una dimensión espacial de 128x128 píxeles, donde sus valores se han normalizado en el rango $[0,1]$ para facilitar el funcionamiento del modelo.
- **Generación de máscaras:** el modelo U-Net pre-entrenado procesa cada radiografía y su máscara dibujada a mano para predecir una máscara binaria propia, una imagen en blanco y negro que delimita exclusivamente la región pulmonar.
- **Aplicación de la máscara:** se realiza una operación de multiplicación matricial entre cada radiografía original y la máscara generada, almacenando las radiografías aisladas en un nuevo conjunto de datos.

[Predicción de máscara](#)

3.3. Estructuración y división de datos procesados

Se han generado dos conjuntos de datos independientes adaptados a cada arquitectura. Para el modelo binario, se han incluido todas las imágenes, etiquetando a la clase “normal” como 0 y agrupando el resto de patologías como 1. Por el contrario, para el modelo multiclase, se han filtrado exclusivamente los pacientes enfermos (dividiendo entre COVID, neumonía y opacidad)

Previo al entrenamiento, las imágenes se han transformado a matrices numéricas, normalizándolas en el rango [0, 1] Finalmente, dividimos entre datos de entrenamiento (80%) y datos de validación (20%), garantizando así que la red procese muestras que no ha visto previamente.

3.4. Diseño del Clasificador Binario

Este modelo constituye la primera etapa del sistema y tiene como objetivo distinguir si el paciente está sano o enfermo.

Se ha diseñado una red neuronal convolucional de tipo estándar, utilizando las siguientes especificaciones:

- **Capa de entrada:** configurada para recibir imágenes de dimensiones 128x128.
- **Bloques de convolución:** dos bloques secuenciales, el primero con 32 filtros y el segundo con 64. Ambos utilizan kernels 3x3 y función de activación ReLu para extracción de características.
- **Reducción de dimensionalidad:** tras cada convolución, se aplica una capa Max Pooling (2x2) para reducir el tamaño espacial de los mapas.
- **Clasificador denso:** una capa Flatten transforma los datos en un vector unidimensional, alimentando a una capa red neuronal densa de 64 neuronas.
- **Regularización:** se incluye Dropout 0.5 (50%) para evitar el sobreajuste debido a la memorización de contenido.
- **Compilación:** optimización con Adam y función de pérdida Binary Crossentropy.
- **Entrenamiento:** 20 épocas, 80% de los datos de entrenamiento.

La característica distintiva de este modelo reside en su capa de salida, con una única salida y función de activación sigmoide, la más adecuada para este caso, pudiendo obtener una probabilidad entre 0 y 1, que equivalen a las dos clases posibles.

3.5. Diseño del Clasificador Multiclase

Una vez determinado que el paciente presenta patología, este segundo modelo se aplica para diferenciar específicamente entre COVID-19, Neumonía Viral y Opacidad Pulmonar. Se entrena exclusivamente con el subconjunto de imágenes patológicas.

Se utiliza también una red neuronal convolucional de tipo estándar, utilizando las siguientes especificaciones:

- **Capa de entrada:** configurada para recibir imágenes con dimensiones 128x128.
- **Bloques de convolución:** se ha aumentado la profundidad de la red en tres bloques secuenciales (filtros de 32, 64 y 128 respectivamente) con kernels 3x3. Al añadir un bloque extra con respecto al modelo binario, permitimos que la red extraiga características más complejas y abstractas.
- **Reducción de dimensionalidad:** tras cada convolución, se aplica una capa Max Pooling (2x2) para reducir el tamaño espacial de los mapas.
- **Clasificador denso:** una capa Flatten transforma los datos en un vector unidimensional, alimentando a una capa red neuronal densa de 128 neuronas.
- **Regularización:** se incluye Dropout 0.5 (50%) para evitar el sobreajuste debido a la memorización de contenido.
- **Compilación:** optimización con Adam y función de pérdida Categorical Crossentropy.
- **Entrenamiento:** 20 épocas, 80% de los datos de entrenamiento.

A diferencia del modelo binario, la capa de salida cuenta con tres neuronas (una por cada clase posible) y utiliza la función de activación Softmax, que convierte las salidas a una distribución de probabilidad donde la suma de todas las clases es igual a 1 (100%), permitiendo identificar la patología.

3.6. Predicción de datos

Para verificar el rendimiento del sistema con datos que la red aún no haya visto, se ha desarrollado un sistema de validación utilizando los modelos ya entrenados previamente.

Para obtener métricas objetivas, se procesan los conjuntos de validación de la siguiente manera:

- **Predicción binaria:** el modelo recibe las imágenes y devuelve un valor entre 0 y 1, aplicando un umbral de decisión 0.5: los valores < 0.5 se etiquetan como normal, los valores ≥ 0.5 se etiquetan como enfermo.
- **Predicción multiclase:** el modelo recibe las imágenes de pacientes enfermos y devuelve un vector de tres probabilidades (Softmax) Se aplica la función Argmax (argumento del máximo) para seleccionar la clase con mayor porcentaje de certeza (COVID, Neumonía Viral u Opacidad) como predicción final.

Por tanto, el trabajo de clasificación consiste en primero introducir una imagen segmentada en el clasificador binario: si el modelo predice que el paciente está sano, termina el análisis. Si en cambio, el modelo predice que el paciente está enfermo, la imagen se deriva al clasificador multiclase, que predice la patología. Todo esto se hace con porcentajes de confianza en ambas clasificaciones.

4. Análisis de resultados

En este capítulo se presentan las métricas de rendimiento obtenidas. El análisis no se limita solamente a la exactitud global, sino que profundiza en indicadores específicos (IoU, sensibilidad, precisión) que son relevantes para el contexto.

4.1. Evaluación de la segmentación (U-Net)

Para validar la etapa de segmentación, se utiliza la métrica IoU (Intersection over Union), que mide el solapamiento entre la máscara predicha por la IA y la máscara real dibujada por expertos.

- **Rendimiento:** el modelo U-Net alcanzó un IoU promedio superior al 95%
- **Interpretación:** este resultado se debe principalmente a dos factores; la arquitectura robusta de la U-Net, y la alta definición de las etiquetas del dataset. Al contar con máscaras binarias muy precisas y con alto contraste, se garantiza que el entrenamiento sea limpio y de calidad. La etiqueta no es una sola palabra, es una imagen con cientos de píxeles.

4.2. Evaluación de la clasificación binaria

En la fase de detección (sano vs. enfermo), la propiedad médica es minimizar el riesgo de no detectar a un paciente contagiado. Por ello, el análisis se enfoca en la sensibilidad.

El análisis de la matriz de confusión es el siguiente:

- **Falsos negativos (error crítico):** el modelo obtuvo un número reducido de falsos negativos (alrededor de 88% de sensibilidad para enfermos, lo que significa que cuando el modelo duda, tiene un sesgo hacia clasificar enfermedad) En medicina, clasificar a un enfermo como “sano” es el escenario más grave, ya que implica enviar a casa a un paciente infectado sin tratamiento, aumentando el riesgo de contagio, e incluso pudiendo representar un peligro para su vida si es paciente de riesgo.
- **Falsos positivos:** aunque existen algunos casos de pacientes sanos clasificados como enfermos, este error se considera aceptable ya que un falso positivo simplemente conlleva que la persona esté en el hospital durante un tiempo hasta que se confirme el negativo.

Matriz de confusión binaria

4.3. Evaluación de la clasificación multiclase

Para el segundo modelo, que opera solamente sobre pacientes enfermos, el objetivo es acertar la patología específica. Por ello, en este modelo prima la precisión.

El análisis de la matriz de confusión es el siguiente:

- **Diferenciación de clases:** el sistema muestra una gran solvencia para detectar Neumonía Viral, diferenciándose claramente de otras patologías.
- **Desafío COVID-19 vs Opacidad:** al analizar los errores de validación, encontramos que hay claras confusiones entre COVID-19 y Opacidad, evidenciando que el modelo es más propenso a equivocarse entre ambas patologías. Esto ocurre porque las radiografías de

COVID-19 y Opacidad pulmonar pueden verse similares en muchos casos, ya que ambas causan “manchas” blancas en los pulmones. Esto no es una limitación del modelo, sino una limitación de las radiografías.

A pesar de esta similitud visual, el modelo logra una tasa de acierto global elevada, que permite utilizarlo como herramienta de apoyo para apoyar la decisión del médico.

Matriz de confusión multiclase

Predicción visual de cuatro imágenes aleatorias dentro de las categorías

5. Conclusiones y justificaciones

A partir del desarrollo del trabajo, y de los resultados del mismo, extraemos una serie de conclusiones que serán fundamentales para entender lo que se ha conseguido, y cómo se puede mejorar y evolucionar.

5.1. Validación de la arquitectura

Se ha estimado oportuno dividir la arquitectura en tres modelos diferentes y bien diferenciados, un segmentador U-Net, un clasificador binario y un clasificador multiclase. Esto se justifica en base a lo siguiente:

- Es necesario seleccionar y aislar únicamente el tejido pulmonar de las radiografías y descartar el resto, para que los clasificadores posteriores trabajen solamente sobre los pulmones y optimicen su funcionamiento, evitando que tengan en cuenta el “ruido” visual para el procesamiento de las imágenes.
- Una vez obtenemos las imágenes segmentadas, necesitamos dividir el proceso de clasificación, ya que primero tendremos que evaluar si el paciente está sano o enfermo antes de aventurarnos a clasificar la patología.

5.2. Limitaciones y alcance del sistema

Aunque el modelo tenga cierta solidez, debemos tener en cuenta que no es del todo fiable, ya que como hemos observado, puede tener ciertas tendencias hacia el error:

- **Con respecto a los clasificadores binarios**, observamos que pueden tener cierta tendencia a predecir falsos negativos y falsos positivos, aunque está balanceado para tender más hacia validar falsos positivos, ya que las implicaciones de dicho error son mucho menos graves.
- **Con respecto a los clasificadores multiclase**, observamos que la mayor tendencia a fallar está en la confusión entre COVID y opacidad pulmonar, ya que sus radiografías en ocasiones pueden ser bastante similares. Deducimos que este fallo no es propio del modelo, sino que responde a problemas propios de la naturaleza de las imágenes.

Esto demuestra que esta arquitectura está pensada como una herramienta de apoyo para los profesionales sanitarios, y en ningún caso como modelo primario de diagnóstico.

5.3. Eficiencia computacional

Los resultados obtenidos demuestran que no hemos necesitado de arquitecturas pesadas como ResNet o VG16 para obtener buenas predicciones.

Se ha priorizado la eficiencia de la arquitectura del sistema, sin perder demasiada precisión, en base a estos parámetros:

- **Reducido coste computacional:** se evita el uso de arquitecturas masivas y profundas, buscando que el modelo pueda entrenarse y ejecutarse en equipos con recursos limitados, como pueden ser ordenadores estándar de hospital.
- **Legibilidad del código:** se ha optado por un código sencillo y limpio, buscando facilitar la comprensión del mismo para facilitar tareas de mejora, mantenimiento y depuración por parte de otros desarrolladores.
- **Simplicidad de los modelos:** en lugar de implementar modelos complejos sin saber qué pasa dentro de ellos, se ha optado por usar modelos más sencillos, explicando paso a paso su funcionamiento y parámetros, buscando facilitar su comprensión.

5.4. Posibles mejoras y ampliaciones

Aunque el sistema cumple con sus objetivos, aún hay espacio para seguir mejorándolo, aumentando su usabilidad y robustez, posiblemente en las siguientes líneas:

- **Integración hospitalaria:** para poder integrarlo en el mundo sanitario, se podría desarrollar una interfaz gráfica para todo el sistema, buscando que personal sanitario sin conocimientos informáticos puedan utilizarlo sin problema.
- **Refinamiento del dataset:** se podría ampliar el conjunto de imágenes y de máscaras con las que entrenamos a la arquitectura, especialmente con casos más confusos como datos de COVID y Opacidad pulmonar que se parezcan mucho. También podemos sopesar utilizar aplicar un filtro más a las radiografías de COVID y Opacidad pulmonar, para mejorar la predicción entre ellos, y reducir confusiones.
- **Mejora de modelos:** se podría sopesar implementar arquitecturas pre-entrenadas más pesadas (como ResNet y EfficientNet) buscando mejorar la precisión en los casos más complicados.
- **Métricas de interpretación:** se podría llegar a implementar un sistema de dibujado “mapas de calor” en los que se muestre al médico qué partes del pulmón ha interpretado el sistema como señales de enfermedad, buscando más claridad en el diagnóstico.

6. Anexos

Figura 1: estructura de una CNN




Figura 2: estructura de un segmentador U-Net





Figura 3: características visuales de cada patología



Pulmones sanos

COVID-19

Neumonía Viral

Opacidad pulmonar

Figura 4: predicción de máscara





Figura 5: aplicación de máscara



Figuras 6 y 7: matrices de confusión clasificaciones en un escenario





Figura 8: resultados visuales de predicciones aleatorias en cada categoría (porcentaje de confianza mostrado también)



7. Bibliografía

Chowdhury, M., Rahman, T., & Khandakar, A. (2022). *COVID-19 Radiography Database*. Kaggle. <https://www.kaggle.com/datasets/tawsifurrahman/covid19-radiography-database>

IBM Cloud Education. (2020). *¿Qué son las redes neuronales convolucionales?* IBM. <https://www.ibm.com/es-es/topics/convolutional-neural-networks>

Knipe, H., & Bell, D. (s.f.). *COVID-19 (pulmonary manifestations)*. Radiopaedia. Recuperado el 12 de enero de 2025, de <https://radiopaedia.org/articles/covid-19-pulmonary-manifestations>

Mayo Clinic. (2021). *Neumonía: Síntomas y causas*. <https://www.mayoclinic.org/es-es/diseases-conditions/pneumonia/symptoms-causes/syc-20354204>

Ronneberger, O., Fischer, P., & Brox, T. (2015). *U-Net: Convolutional Networks for Biomedical Image Segmentation*. arXiv. <https://arxiv.org/abs/1505.04597>

Brownlee, J. (2020). *A Gentle Introduction to the Rectified Linear Unit (ReLU)*. Machine Learning Mastery. <https://machinelearningmastery.com/rectified-linear-activation-function-for-deep-learning-neural-networks/>

Scikit-learn developers. (s.f.). *Metrics and scoring: Quantifying the quality of predictions*. Scikit-learn. https://scikit-learn.org/stable/modules/model_evaluation.html

Stanford University. (s.f.). *CS231n: Convolutional Neural Networks for Visual Recognition*. Stanford Vision Lab. <https://cs231n.github.io/convolutional-networks/>